

Universität Potsdam
Computerlinguistische Techniken
Dozent:
Prof. Dr. David Schlangen
Wintersemester 2020/21

Bericht

Terminologie Extraktion

Name: Katja Konermann
Matrikelnummer: 802658
Email: katja.konermann@uni-potsdam.de

Inhaltsverzeichnis

1	Korpus und Kandidatenauswahl	1
2	Auswertung	1
3	Bewertung	3
4	Code	4
5	Literatur	4

1 Korpus und Kandidatenauswahl

Der *acl* Korpus besteht aus etwa 11 000 Dokumenten, die insgesamt mehr als 1.5 Millionen Sätzen und 42 Millionen Token enthalten. Die Types belaufen sich auf zirka 520 000 (siehe *Tabelle 1*) Die Zahl der ausgewählten Bigram-Kandidaten beträgt etwa 340 000.

Zur Auswahl der Kandidaten wurden verschiedene Parameter genutzt. So werden alle Bigramme herausgefiltert, in denen eines oder beider der Token in einer Menge von Stoppwörtern vorkommt. Ich habe dafür die englischen Stoppwörter von *nlTK* verwendet. Im Projekt sind sie in der Datei *data/stops.en.txt* zu finden.

Weil Fachbegriffe zumeist aus Nomen bestehen sollten, habe ich zudem Tagging verwendet. Dabei muss ein Bigramm aus zumindest einem relevanten Tag bestehen, um als Kandidat in Frage zu kommen. Mithilfe von *nlTKs Averaged Perceptron Tagger* werden so alle Bigramme getaggt und die Bigramme, die keinerlei relevante Tags enthalten, herausgefiltert. Als relevante Tags habe ich hier *NN* (Noun, singular or mass), *NNS* (Noun, plural) und *NNP* (Proper noun, singular) genutzt.

Da das *acl* Korpus durch *optical character recognition* erstellt wurde, sind viele Zeichen vorhanden, die keinerlei Bedeutung haben. Um diese Bigramme herauszufiltern, wird bei der Kandidatenauswahl zusätzlich getestet, ob ein Bigramm aus Token besteht, die ausschließlich alphabetisch sind.

Die Anzahl der Kandidaten kann außerdem reduziert oder erhöht werden, indem ein Minimum für die absolute Häufigkeit eines Bigramms festgelegt wird. Ich habe für die Kandidatenauswahl hier eine Häufigkeit von 3 gewählt.

Die Kandidaten, die schließlich für die Terminologieextraktion genutzt wurde, sind in der Datei *data/candidates.txt* gespeichert. Um diese Liste von Termen zu reproduzieren, können folgende Argumente bei der Ausführung von *main.py* an die Kommandozeile übergeben werden:

```
candidates --stops data/stops_en.txt --min_count 3 acl_texts/ <file> NN NNS NNP
```

Dabei sollte *<file>* durch den gewünschten Namen der Ausgabedatei ersetzt werden. Für genauere Information zu den einzelnen Argumenten siehe Abschnitt *Anwendung* oder die *README*.

Dokumente	10 922
Sätze	1 575 233
Token	42 482 606
Types	520 446
Kandidaten (Bigramme)	341 517

Tabelle 1: Korpus und Kandidaten

2 Auswertung

Bei der Extraktion der Fachbegriffe habe ich verschiedene Parameter getestet. Die Werte für den Parameter α habe ich so gewählt, dass verschiedene Gewichtungen der Domänenrelevanz und des Domänenkonsens betrachtet werden können. Der Wert für den Parameter θ wurde dabei für jedes α so gewählt, dass die Anzahl der Kandidaten ungefähr vergleichbar ist, wobei einige Werte für θ absichtlich höher (*output2.csv*) oder niedriger (*output1.csv*) gesetzt wurden, um zu betrachten, wie dies die Leistung des Systems beeinflusst. Die Werte der Parameter mit der dazugehörigen Anzahl der Fachbegriffe sind in *Tabelle 2* aufgeführt.

Für die verschiedenen Parameterwerte werden *Recall*, *Precision* und das harmonische Mittel aus beiden, der *F1-Score*, in *Abbildung 1* dargestellt.

Dabei fällt auf, dass es zwischen den unterschiedlichen Werten für α und θ keine großen Unter-

Datei	α	θ	Fachbegriffe
output/output1.csv	0.5	2	20 404
output/output2.csv	0.75	1.75	4 957
output/output3.csv	0.25	2.75	13 495
output/output4.csv	0.9	1.25	9 965
output/output5.csv	0.1	3	15 818

Tabelle 2: Anzahl der Fachbegriffe

schiede in der Leistung zu geben scheint: Der *F1-Score* pendelt sich oft bei etwa 15% ein. Für $\alpha = 0.5$ und $\theta = 2$ in der Datei *output/output1.csv*, für die die Kandidatenzahl relativ groß ist, ist auch der *Recall*-Wert mit über 18% höher im Vergleich mit den anderen Parametern. Dafür fällt *Precision* mit etwa 13% jedoch im Gegensatz niedriger aus. Umgekehrt ist die Trefferquote von ca. 8% für $\alpha = 0.75$ und $\theta = 1.75$ mit einer Kandidatenzahl von um die 5000 deutlich niedriger, während die *Precision* mit über 20% vergleichsweise hoch ist. Das könnte darauf hindeuten, dass der Anteil von korrekten Termen höher ist, wenn auch die Punktzahl höher ist. Im oberen Wertebereich der extrahierten Terme sind somit eher richtige Fachbegriffe.

Es ist zudem auffallend, dass die *Precision* höher ist, wenn die Domänenrelevanz höher ge-




Abbildung 1: Accuracy verschiedener Parameter

wichtet wird, also für Werte von $\alpha > 0.5$. Die *Recall*-Werte sind dagegen höher, wenn dem Domänenkonsens mit Werten für $\alpha < 0.5$ mehr Gewicht zugesprochen wird. Da hier jedoch nur fünf Kombinationen für α und θ ausprobiert wurden, kann nicht eindeutig beurteilt werden, ob dies eine allgemeingültige Tendenz ist. Außerdem ist die Anzahl der extrahierten Terme, für $\alpha > 0.5$ gleichzeitig immer niedriger, was auch die *Precision* erhöhen könnte.

$\alpha = 0.5, \theta = 2$	$\alpha = 0.75, \theta = 1.75$	$\alpha = 0.25, \theta = 2.75$	$\alpha = 0.9, \theta = 1.25$	$\alpha = 0.1, \theta = 3$
et al (4.68)	et al (2.84)	et al (6.53)	et al (1.73)	et al (7.63)
natural language (4.53)	natural language (2.77)	natural language (6.3)	natural language (1.71)	natural language (7.36)
language processing (4.35)	language processing (2.67)	language processing (6.02)	language processing (1.67)	language processing (7.03)
training data (4.14)	training data (2.57)	training data (5.71)	training data (1.63)	training data (6.65)
next section (4.14)	next section (2.57)	next section (5.71)	next section (1.63)	next section (6.65)
computational linguistics (4.12)	computational linguistics (2.56)	computational linguistics (5.68)	computational linguistics (1.62)	computational linguistics (6.62)
future work (4.12)	future work (2.56)	future work (5.63)	future work (1.62)	future work (6.61)
machine translation (4.1)	machine translation (2.55)	machine translation (5.65)	machine translation (1.62)	machine translation (6.58)
test set (4.03)	test set (2.51)	large number (5.58)	test set (1.61)	large number (6.54)
paper describes (4.02)	paper describes (2.51)	test set (5.54)	paper describes (1.60)	total number (6.48)

Tabelle 3: Extrahierte Terme mit der höchsten Punktzahl

$\alpha = 0.5, \theta = 2$	$\alpha = 0.75, \theta = 1.75$	$\alpha = 0.25, \theta = 2.75$	$\alpha = 0.9, \theta = 1.25$	$\alpha = 0.1, \theta = 3$
tagging tool (2)	use simple (1.75)	extraction applications (2.75)	adjacent word (1.25)	intended sense (3)
recognition method (2)	considerable effort (1.75)	equal length (2.75)	constraints expressed (1.25)	new classes (3)
current implementations (2)	many approaches (1.75)	google search (2.75)	discourse features (1.25)	first parser (3)
h c (2)	closer examination (1.75)	specialized domain (2.75)	demonstrative pronoun (1.25)	descriptive adequacy (3)
cornell university (2)	average recall (1.75)	different modalities (2.75)	distinctive feature (1.25)	english preposition (3)
internal semantic (2)	shallow semantic (1.75)	n r (2.75)	best features (1.25)	manual translation (3)
linguistic constituents (2)	language users (1.75)	feature bundles (2.75)	standard machine (1.25)	grained analysis (3)
common terms (2)	training methods (1.75)	translation equivalent (2.75)	multimodal dialogue (1.25)	internet search (3)
subordinate conjunction (2)	integrated approach (1.75)	structural rules (2.75)	pos features (1.25)	intervening material (3)
asr systems(2)	semantic rule (1.75)	phonemic transcription (2.75)	unification process (1.25)	lexical processing (3)

Tabelle 4: Extrahierte Terme mit der niedrigsten Punktzahl

In *Tabelle 3* sind für jede der fünf Parameterkombination die zehn Begriffe aufgeführt, die die höchste Punktzahl erzielt haben. Diese Terme sind über die Kombinationen hinweg meist dieselben. Es scheint hier nur wenig Variation zu geben. Das wird höchstwahrscheinlich daran liegen, dass diese Begriffe über die Dokumente hinweg sehr häufig auftreten und damit einen hohen Konsenswert besitzen. Der Domänenkonsens kann im Gegensatz zur Domänenrelevanz größer als eins sein; sein Maximum ist dabei durch die Anzahl der Dokumente bestimmt (siehe Abschnitt *Bewertung*). Der Einfluss des Domänenkonsens ist damit oft größer als der der Domänenrelevanz. Begriffe, die in allen Dokumenten ähnlich frequent auftreten, werden bei der Extraktion so übermäßig bevorzugt. Darum ist es nicht sehr verwunderlich, dass *et al* für alle Parameter der Terminus mit der höchsten Punktzahl ist. Auch Terme wie *paper describes*, *future works* oder *next section*, die in wissenschaftlichen Arbeiten allgemein häufig auftreten, fallen in diese Kategorie.

In den höchst bewerteten Begriffen finden sich jedoch auch Termini wie *computational linguistics*, *language processing* oder *machine translation*, die durchaus als gute Fachbegriffe angesehen werden können.

In *Tabelle 4* werden für jede der fünf Parameterkombination die zehn Begriffe aufgeführt, die noch als Terminologie angesehen werden, also jeweils θ überschritten haben, aber die niedrigste Punktzahl erreicht haben.

3 Bewertung

Qualitativ schneidet das System meiner Meinung nach nicht zu schlecht ab. Zwar sind unter den extrahierten Termini durchaus Ausdrücke wie *next section* oder *paper describes*, die eher bedeutungslos für die Computerlinguistik scheinen. Zumindest sind mir aber in den extrahierten Terme keine Begriffe aufgefallen, die offensichtlich nichts mit der Domäne Computerlinguistik zu tun haben, obwohl Begriffe wie *monetary policy* oder *central bank* durchaus in den Kandidaten vorkamen.

Mit einer Accuracy von etwa 15% im Durchschnitt weist das Programm quantitativ jedoch eine eher schlechte Leistung auf. Dafür könnte es verschiedene Gründe geben. Zum einen könnte die

$\alpha = 0.5, \theta = 2$	$\alpha = 0.75, \theta = 1.75$	$\alpha = 0.25, \theta = 2.75$	$\alpha = 0.9, \theta = 1.25$	$\alpha = 0.1, \theta = 3$
NA	Na	NA	NA	NA
NA	Na	NA	NA	NA
NA	Na	NA	NA	NA
NA	Na	NA	NA	NA
NA	Na	NA	NA	NA
NA	Na	NA	NA	NA
NA	Na	NA	NA	NA
NA	Na	NA	NA	NA
NA	Na	NA	NA	NA
NA	Na	NA	NA	NA
NA	Na	NA	NA	NA

Tabelle 5: Ausgeschlossene Terme mit der niedrigsten Punktzahl

Vorverarbeitung und damit die Kandidatenauswahl verbessert werden. Wie im vorherigen Abschnitt beobachtet enthalten die extrahierten Terme oft noch Bigramme, die etwa aus Verben bestehen. Ich glaube, hier könnte es hilfreich sein, das Tagging noch weiter zu verfeinern, indem beispielsweise eine Tabu-Liste von Tags geschaffen wird, die in den Kandidaten nicht vorkommen dürfen. Als andere Möglichkeit könnte festgelegt werden, dass etwa das zweite Wort in einem Bigram als Nomen getaggt werden muss, um als Kandidat in Betracht gezogen zu werden. Derzeit muss nur eins der beiden Worte in einem Bigramm ein Nomen. Ich glaube, wenn immer das zweite Wort als Nomen getaggt werden sollte, könnten sinnvollere Kandidaten extrahiert werden. Ein weiterer Faktor für die schlechte Leistung könnte meiner Meinung nach der Referenzkorpus sein: Es wäre interessant zu untersuchen, ob das System mit einem Korpus, der Paper aus anderen Forschungsbereichen enthält, eine bessere Leistung schaffen würde. Damit könnten beispielsweise Begriffe wie *et al* oder *paper describes* eher als irrelevant für die Domäne Computerlinguistik eingestuft werden, weil diese auch in anderen wissenschaftlichen Arbeiten häufig auftreten sollten. Ein weiteres Problem für das Programm sind zudem die unterschiedlichen Wertebereiche von Domänenkonsens und Domänenrelevanz. Während der Wert eines Begriffs für die Relevanz maximal eins sein kann, ist der Limit für den Domänenkonsens abhängig von der Anzahl der Dokumente. Der maximale Wert der Domänenkonsens ist dabei $\log(N)$, wobei N die Anzahl der Dokumente ist. In diesem Fall heißt das, dass ein Begriff einen Wert von etwa 9.3 erhalten könnte, wenn er in allen Dokumenten die gleiche Frequenz aufweist.

Damit fällt der Domänenkonsens jedoch oft viel mehr ins Gewicht als die Domänenrelevanz. Um dieses Problem zu umgehen, könnte beispielsweise eine normalisierte Entropie genutzt werden, wobei der vorherige Entropiewert H für einen Term t durch den maximalen Wert $H_{max} = \log(N)$ dividiert wird:

$$H_{norm}(t) = \frac{H(t)}{H_{max}}$$

Damit hätten sowohl Domänenrelevanz als auch -konsens den gleichen Wertebereich $[0, 1]$ und wären so besser zu vergleichen und gewichten

4 Code

5 Literatur

- https://www.ling.upenn.edu/courses/Fall_2003/ling001/penn_treebank_pos.html

- NORMAL ENTROPIE